

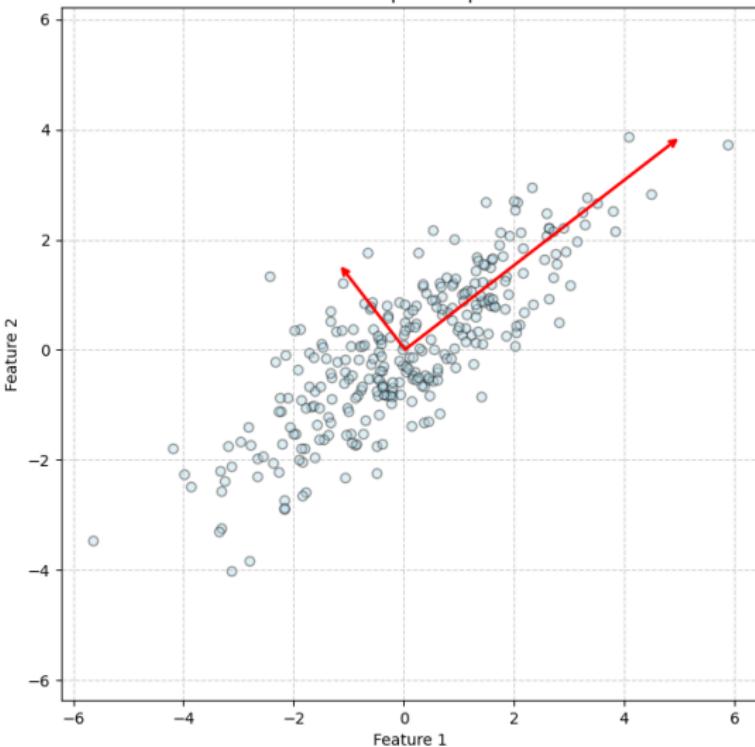
Principal Component Analysis - PCA

15 lutego 2026

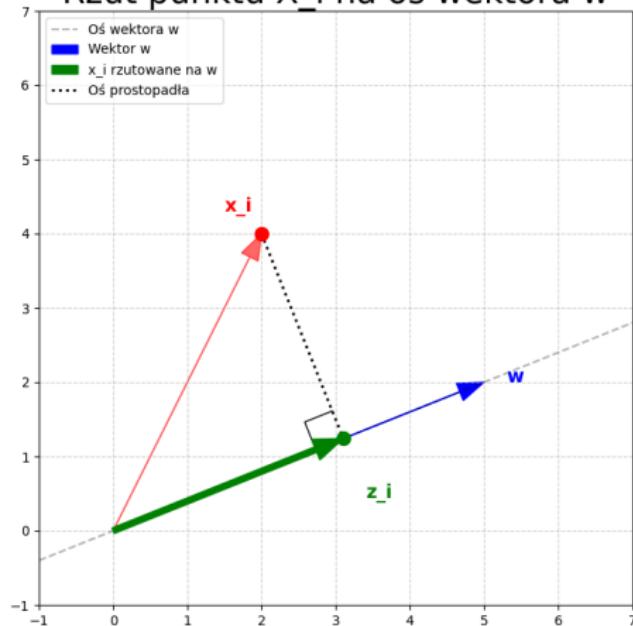
Na początku zdefiniujemy, jak wyglądają nasze dane. Wektory X_i , o wymiarach $d \times 1$, reprezentują obserwacje o d cechach. Natomiast \mathbb{X} ($n \times d$) jest tablicą składającą się z transponowanych wektorów X_i .

$$X_i = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} \quad \mathbb{X} = \begin{bmatrix} \quad X_1^T \quad \quad \\ \quad X_2^T \quad \quad \\ \vdots \\ \quad X_n^T \quad \quad \end{bmatrix}$$

2D Data with Principal Component Vectors



Rzut punktu X_i na oś wektora w



$$\|w\| = 1$$

$$z_i = \langle X_i, w \rangle = X_i^T w$$

Naszym zadaniem będzie znalezienie takiego wektora w , który zmaksymalizuje wariancję, gdy rzutujemy na niego punkty X_i . Przy tym założymy, że dane są znormalizowane (wszystkie cechy mieszczą się w przedziale $[0, 1]$) i mają średnią $\mu = 0$.

$$\begin{aligned}\text{wariancja} = \sigma^2 &= \frac{1}{n} \sum_{i=1}^n (z_i)^2 = \frac{1}{n} \sum_{i=1}^n (X_i^T w)^2 = \frac{1}{n} (\mathbb{X}w)^T \mathbb{X}w \\ &= w^T \left(\frac{1}{n} \mathbb{X}^T \mathbb{X} \right) w = w^T S w\end{aligned}$$

S jest macierzą kowariancji. Jest ona symetryczna, dlatego

$$\begin{aligned}v_1 \perp v_2 \perp \dots \perp v_d, \quad &\|v_i\| = 1 \\ \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d, \quad &\lambda_i \in \mathbb{R}\end{aligned}$$

Gdzie v_i są wektorami własnymi S , a λ_i odpowiadającymi im wartościami własnymi.

Wektory v_i tworzą przestrzeń ortonormalną, dlatego możemy zapisać wektor w jako kombinację liniową:

$$w = \sum_{i=1}^d c_i v_i$$

Korzystając z warunku długości wektora w , możemy ograniczyć wartości współczynników c_i

$$\|w\| = 1 \implies \left(\sum_{i=1}^d c_i v_i \right)^T \sum_{i=1}^d c_i v_i = 1 \implies \sum_{i=1}^d c_i^2 = 1$$

Podstawiamy nowy wzór na w , pamiętając, że wektory własne spełniają równanie $Sv = \lambda v$.

$$Sw = S \left(\sum_{i=1}^d c_i v_i \right) = \sum_{i=1}^d \lambda_i c_i v_i$$

$$w^T Sw = \left(\sum_{i=1}^d c_i v_i \right)^T \left(\sum_{i=1}^d \lambda_i c_i v_i \right) = \sum_{i=1}^d \lambda_i c_i^2$$

Co daje nam nowy wzór na wariancję:

$$\sigma^2 = \sum_{i=1}^d \lambda_i c_i^2$$

Przypomnijmy sobie, że naszym celem jest znalezienie takiego wektora w , który zmaksymalizuje wariancję, dlatego

$$\sup \sigma^2 = \sup_{c_i} \sum_{i=1}^d \lambda_i c_i^2 = \max\{\lambda_i; \quad i \in \{1, 2, \dots, d\}\}$$

Z tego wynika, że $c_i = 1$, gdy $\lambda_i = \max\{\lambda\}$, w przeciwny razie $c_i = 0$.

Dzięki temu, wnioskujemy, że wektor w maksymalizujący wariancję, jest wektorem własnym macierzy S , odpowiadającym największej wartości własnej.

$$w = v_1 \quad \text{oraz} \quad \sigma^2 = \lambda_1$$