Principal Component Analysis (PCA)

Redukcja Wymiarów i Ekstrakcja Cech

Piotr Kędzierski & Mariusz Godlewski

Czym jest PCA?

Principal Component Analysis (PCA) jest metodą nienadzorowanego uczenia maszynowego używaną do upraszczania z skomplikowanych zbiorów danych.

- **Redukcja Wymiarów:** PCA zmniejsza ilość zmiennych (wymiarów) używanych do opisu
- **Zachowanie Informacji:** Stara się zachować jak najwięcej wariancji (w domyśle ważnych cech) przy jak najmniejszej ilości komponentów.
- **Usunięcie Korelacji:** Zamienia zbiór skorelowanych zmiennych w nową – liniowo niezależną bazę składającą się z wektorów nazywanych *głównymi składowymi*.

Intuicja

Wyobraźmy sobie chmurę punktów w trzech wymiarach.

PCA znajduje nową bazę (układ współrzędnych) dla tego zbioru danych:

1. **Pierwsza Główna Składowa (PC1)** jest prostą, która zachowuje najwięcej wariancji po rzutowaniu na nią punktów.
2. **Druga Główna Składowa (PC2)** jest prostopadła (ortogonalna) do pierwszej i jest drugą pod względem zachowywanej wariancji.
3. Ten proces kontynuować można n razy, usuwając te składowe, które zachowują najmniej wariancji, upraszczając i kompresując w ten sposób dane.

Podłoże Matematyczne

Jak znajduje się Główne Składowe?

- Po pierwsze, należy znaleźć **Macierz Kowariancji**, S.
- Ponieważ S jest symetryczna i ma rzeczywiste elementy, Twierdzenie Spektralne gwarantuje istnienie ortogonalnych wektrów własnych.
- **Wektory Własne** (v) są Głównymi Składowymi (nowym układem współrzędnych).
- **Wartości Własne** (λ) określają wariancję zachowywaną przez konkretną składową.

Wizualizacja
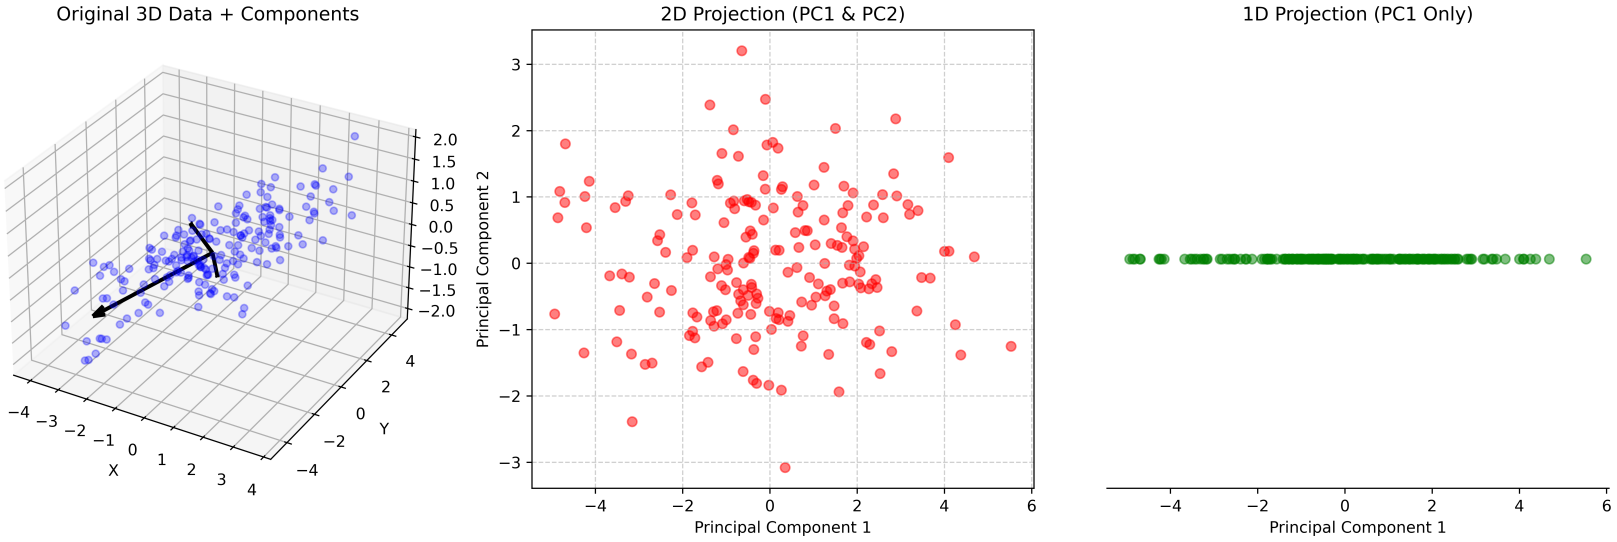
- **3D:** Czarne strzałki oznaczają ortogonalne wektory własne (długości odpowiadające wariancjom).
- **2D:** Ignorujemy najkrótszy wektor i rzutujemy punkty na dwa pozostałe, dalej zachowując ogólną formę zbioru.
- **1D:** Zostawiamy jedynie kierunek odpowiadający wektorowi własnemu z największą wartością własną.