Cel

Postaramy się zredukować wielowymiarowy zbiór $\mathcal{X} = \{x_1, x_2, \ldots x_n\}$, do $\mathcal{Y} = \{y_1, y_2, \ldots y_n\}$

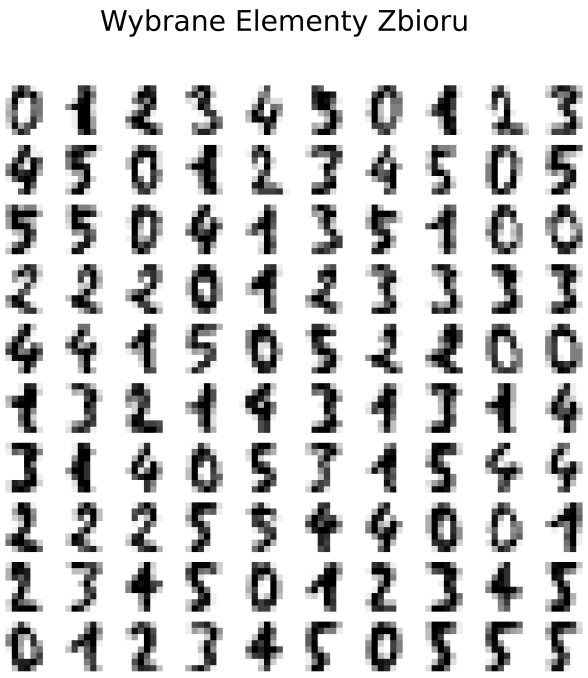

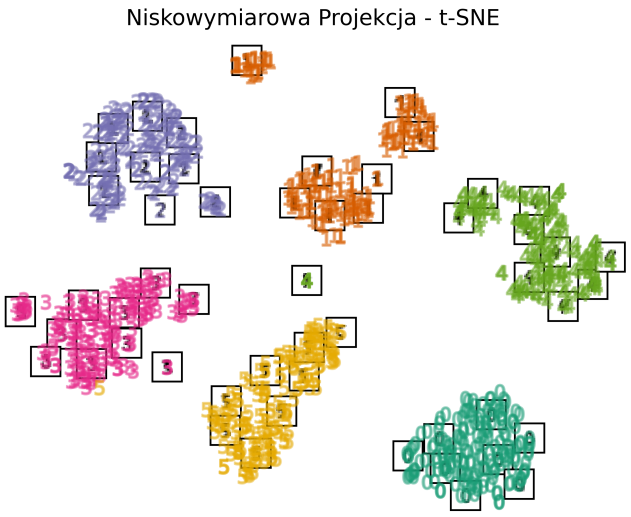

Rysunek: Projekcja zbioru MNIST na dwa wymiary

Prawdopodobieństwa Warunkowe

t-SNE – *t-Distributed Stochastic Neighbor Embedding*, jest metodą redukcji wymiarów danych. Działa ona, przez zamienienie odległości na prawdopodobieństwa warunkowe, określające stopień podobieństwa dwóch punktów, a następnie przeniesienie tego rozkłady do $k < n$ wymiarów.

Definition

Prawdopodobieństwo $p_{j|i}$ (x_i wybierający punkt x_j jako sąsiada

$$p_{j|i} = \frac{e^{(-\|x_i - x_j\|^2/2\sigma_i^2)}}{\sum_{k \neq i} e^{(-\|x_i - x_k\|^2/2\sigma_i^2)}}$$

Ustalamy $\forall_i \quad p_{i|i} = 0$.

Symetria

Ponieważ σ_i jest różna dla każdego punktu, $p_{j|i} \neq p_{i|j}$. Żeby uzyskać symetrię definiujemy

Definition (Łączony Rozkład Prawdopodobieństwa)

$$p_{ij} = p_{ji} = \frac{p_{i|j} + p_{j|i}}{2n}$$

Główną zaletą symetrycznego rozkładu jest prosta forma gradientu funkcji.

Rozkład w Niskowymiarowej Przestrzeni

W zredukowanej przestrzeni, będziemy korzystać z *rozkładu t-studenta*, aby rozwiązać problem kongregacji punktów.

Definition

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l}(1 + \|y_k - y_l\|^2)^{-1}}$$

Oraz ponownie $\forall_i \quad q_{ii} = 0$.

Warto zauważyć, że ponieważ Q i P są rozkładami, to $\sum_{i,j} p_{ij} = \sum_{i,j} q_{ij} = 1$.

Rozkład w Niskowymiarowej Przestrzeni

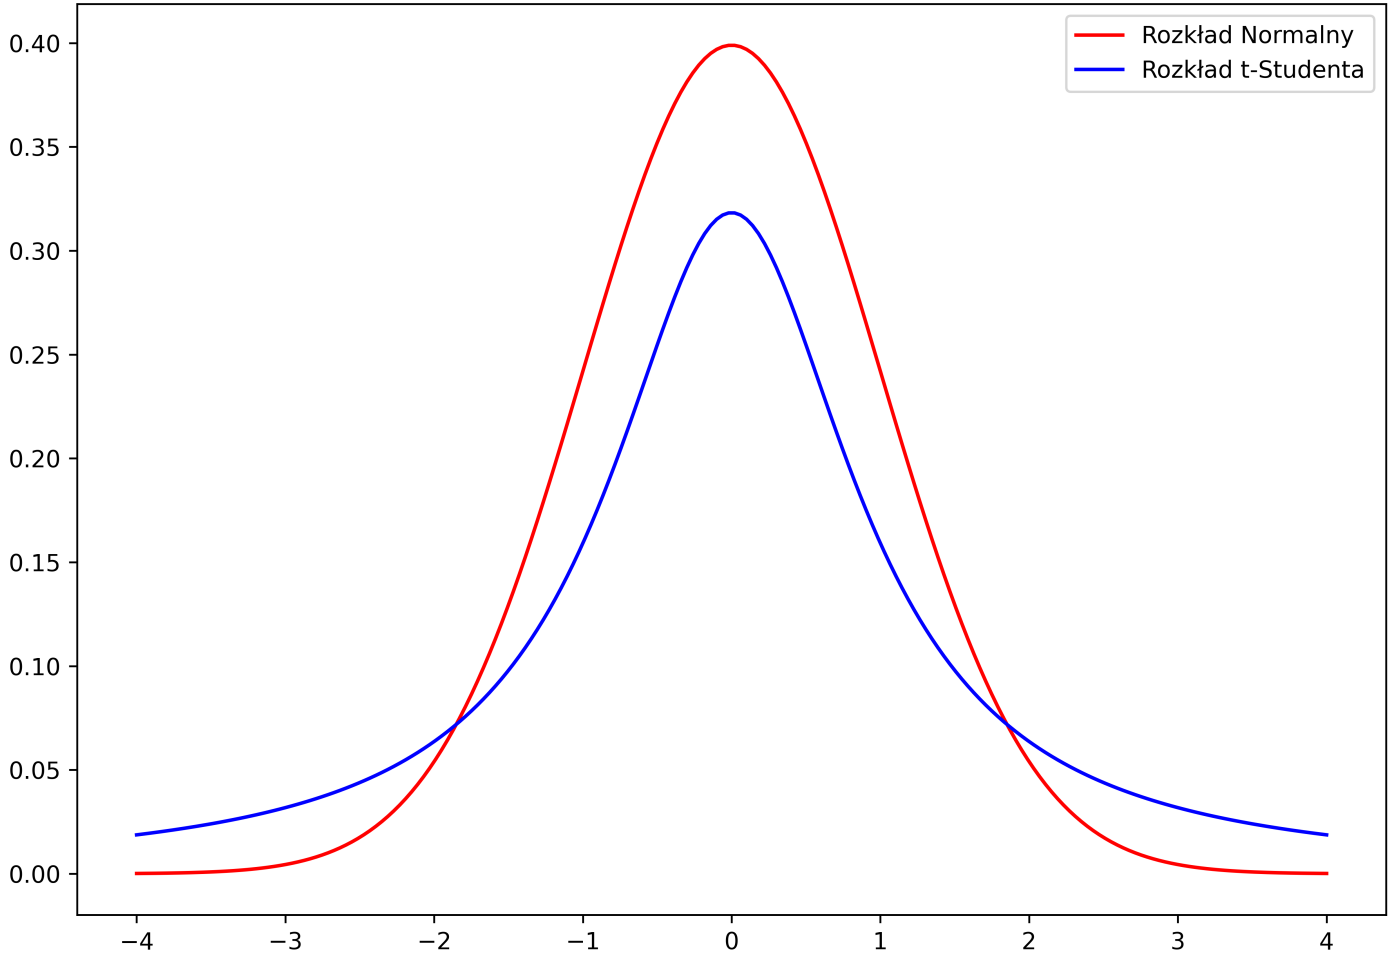

Czym jest σ_i?

Wariancja σ_i^2, zależy od podanej wartości parametru – *perplexity*. Na jej podstawie (dla każdego punktu x_i osobno) szukamy takiej wartości, aby

$$Perp(P_i) = 2^{H(P_i)}$$

Definition (Entropia Shannona)

$$H(P_i) = -\sum_j p_{j|i} \log_2(p_{j|i})$$

Perplexity – parametr. Można go (luźno) interpretować jako liczbę „ważnych" sąsiadów.

Mierzenie Podobieństwa Rozkładów

Definition (Rozbieżność Kullbacka-Leiblera)

Jest to metoda mierzenie rozbieżności dwóch rozkładów prawdopodobieństwa

$$KL(P||Q) = \sum_i \sum_j p_{ij} \log\left(\frac{p_{ij}}{q_{ij}}\right).$$

Będziemy ją traktować jak *funkcję kosztu*.

$$C = KL(P||Q).$$

Gradient Funkcji Kosztu

Spróbujemy zobaczyć jak zmienia się błąd, przy przesunięciu jednego punktu w niskowymiarowej mapie $-\frac{\partial C}{\partial y_i}$.

$$C = \sum_i \sum_{j \neq i} p_{ij} \log\left(\frac{p_{ij}}{q_{ij}}\right) = \underbrace{\sum_i \sum_{j \neq i} p_{ij} \log(p_{ij})}_{\text{const.}} - \sum_i \sum_{j \neq i} p_{ij} \log(q_{ij})$$

Dodatkowo wprowadzimy oznacznia

$$w_{ij} = (1 + \|y_i - y_j\|^2)^{-1}, \qquad Z = \sum_k \sum_{l \neq k} w_{kl}, \qquad q_{ij} = \frac{w_{ij}}{Z}$$

$$C = \text{const.} - \sum_k \sum_{k \neq l} p_{kl} \log(w_{kl}) + \sum_k \sum_{k \neq l} p_{kl} \log(Z)$$

Gradient Funkcji Kosztu

Na początku obliczymy pochodne w_{ij} i Z

$$\frac{\partial w_{ij}}{\partial y_i} = -(1 + \|y_i - y_j\|^2)^{-2} \cdot \frac{\partial(\|y_i - y_j\|^2)}{\partial y_i} = -2w_{ij}^2(y_i - y_j)$$

Ponieważ Z jest sumą wszystkich par, y_i pojawia się tylko wtedy, gdy $k = i$ lub $l = i$, a ponieważ $w_{ij} = w_{ji}$, mnożymy wynik przez 2

$$\frac{\partial Z}{\partial y_i} = 2\sum_{j \neq i} \frac{\partial w_{ij}}{\partial y_i} = -4\sum_{j \neq i} w_{ij}^2(y_i - y_j)$$

Gradient Funkcji Kosztu

Teraz możemy różniczkować całą funkcję C.

$$\frac{\partial C}{\partial y_i} = -\sum_k \sum_{l \neq k} p_{kl} \frac{\partial \log(w_{kl})}{\partial y_i} + \sum_k \sum_{l \neq k} p_{kl} \frac{\partial \log(Z)}{\partial y_i}$$

$$\frac{\partial C}{\partial y_i} = \underbrace{-\sum_k \sum_{l \neq k} \frac{p_{kl}}{w_{kl}} \frac{\partial w_{kl}}{\partial y_i}}_{I_1} + \underbrace{\sum_k \sum_{l \neq k} p_{kl} \frac{1}{Z} \cdot \frac{\partial Z}{\partial y_i}}_{I_2}$$

Pochodna $\frac{\partial w_{kl}}{\partial y_i}$ jest różna od zera tylko gdy $k = i$ lub $l = i$

$$I_1 = 2 \sum_{j \neq i} \frac{p_{ij}}{w_{ij}} \frac{\partial w_{ij}}{\partial y_i} = -4 \sum_{j \neq i} p_{ij} w_{ij} (y_i - y_j)$$

Gradient Funkcji Kosztu

Zauważmy, że Z nie zależy od indeksów sumy oraz $\sum_{k,l} p_{kl} = 1$

$$I_2 = \sum_k \sum_{l \neq k} p_{kl} \frac{1}{Z} \frac{\partial Z}{\partial y_i} = \frac{1}{Z} \frac{\partial Z}{\partial y_i} = -4 \sum_{j \neq i} q_{ij} w_{ij} (y_i - y_j)$$

Dzięki temu otrzymujemy

$$\frac{\partial C}{\partial y_i} = -I_1 + I_2 = 4 \sum_{j \neq i} (p_{ij} - q_{ij}) w_{ij} (y_i - y_j)$$

$$\frac{\partial C}{\partial y_i} = 4 \sum_{j \neq i} (p_{ij} - q_{ij}) (1 + \|y_i - y_j\|^2)^{-1} (y_i - y_j)$$

Algorytm

Dane: wielowymiarowy zbiór $\mathcal{X} = \{x_1, x_2, \ldots, x_n\}$;
Parametry: *Perplexity*; ilość kroków T; moment pędu $\alpha(t)$; szybkość uczenia η;
Rezultat: niskowymiarowa mapa $\mathcal{Y}^{(t)} = \{y_1, y_2, \ldots, y_n\}$;

Początek

Oblicz prawdopodobieństwa $p_{j|i}$, z ustaloną wartością *perplexity*

Ustal $p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$

Wybierz stan początkowy $\mathcal{Y}^{(0)}$ z $\mathcal{N}(0, 10^{-4} I)$

for $t = 1$ **to** T **do**

Oblicz niskowymiarowe prawdopodobieństwa q_{ij};

Oblicz Gradient $\frac{\partial C}{\partial \mathcal{Y}}$;

Ustal $\mathcal{Y}^{(t)} = \mathcal{Y}^{(t-1)} + \eta \frac{\partial C}{\partial \mathcal{Y}} + \alpha(t) \left(\mathcal{Y}^{(t-1)} - \mathcal{Y}^{(t-2)} \right)$;